Ejercicio Semana 11 clase 2

INF144

El **text mining** (minería de texto) es un conjunto de técnicas de informática, inteligencia artificial y lingüística computacional que permite extraer información útil, patrones y conocimiento a partir de grandes volúmenes de texto no estructurado, como documentos, correos, noticias, reseñas o publicaciones en redes sociales. Su funcionamiento se basa en transformar el texto en datos que un computador pueda procesar, mediante etapas como la tokenización, la normalización, la eliminación de palabras vacías y el conteo de frecuencias, para luego aplicar algoritmos de análisis estadístico o de aprendizaje automático. Se utiliza en múltiples aplicaciones, entre ellas los motores de búsqueda y la recuperación de información, el análisis de sentimientos sobre productos o servicios, la clasificación automática de documentos, la detección de spam, la generación de resúmenes, la identificación de temas dominantes en un conjunto de textos y la detección de fraudes o plagio.

La Biblioteca Digital de su universidad está digitalizando cuentos, fábulas y noticias. Para ofrecer un buscador inteligente, el equipo de **minería de texto (text mining)** necesita una herramienta que lea un texto y sepa cuales son las palabras más frecuentes, cuántas son **palabras de contenido** (las que dicen de qué trata el texto) y cuántas son **palabras vacías** (las que solo sirven de enlace) y si hay palabras que el sistema no reconoce.

Para esto usted debe identificar el corpus(texto a analizar en el archivo texto.txt). Tokenizar el corpus (separando el texto en palabras individuales o tokens), normalizar las palabras (pasando todo a minúsculas). Identificar las stopwords (Palabras muy comunes con poco significado propio: artículos, pronombres, preposiciones, que están en otros.txt.). Identificar palabras de contenido (Sustantivos y verbos, que portan el significado. Están en palabras.txt). Identificar el vocabulario, que es el conjunto de palabras distintas del texto(al menos aparecieron una vez en el texto). Calcular la frecuencia absoluta de las palabras (Veces que aparece una palabra / esas veces divididas entre el total de tokens.

palabras.txt

```
es
ojos
abuelo
dijo
esperaba
trozo
amistad
conto
puerta
….
```

contiene el diccionario de **palabras de contenido**: sustantivos y verbos en la forma en que aparecen en el texto. Hay una palabra por línea y no se indica cuántas son. Tampoco están necesariamente ordenadas.

otros.txt

```
tambien
que
en
sin
luego
entre
otros
poco
…
```

contiene las **palabras vacías**: artículos, pronombres, preposiciones, conjunciones, etc. Tiene el mismo formato.

texto.txt

```
Hace mucho tiempo, en un pueblo junto a un rio, vivia una muchacha
llamada Lucia. La muchacha tenia un perro, ……
```

contiene el texto a analizar. Es texto libre, con mayúsculas, signos de puntuación y varias líneas.

Observen que las palabras `amarillos` y `fresco` no están en ninguno de los dos diccionarios. Eso generará palabras **desconocidas**. Considere que el texto en el archivo texto.txt tiene un máximo de 600 palabras. Recuerde que ya puede usar las funciones de la libreria cstring.

A continuación se detallan las tareas a realizar:

1. **Cargar los diccionarios.** Recorra cada archivo(palabras.txt y 0tros.txt) dos veces: una para contar las palabras y reservar la memoria exacta, y otra para guardarlas en `char *dicPalabras[]` y `char *dicOtros[]`, debe usar memoria dinámica.

2. Imprima un reporte simple en el que se muestren los datos de los dos diccionarios de cadenas que ha creado en el punto anterior.
3. Ordene ambos diccionarios alfabéticamente, sin utilizar un arreglo adicional.

4. Imprima un reporte simple en el que se muestren los datos de los dos diccionarios de cadenas que ha ordenado en el punto anterior.
5. **Lea el texto (texto.txt) y tokenicelo.** Normalice cada token (minúsculas, sin signos). **Clasifique cada token** con **búsqueda binaria**: si está en `dicOtros` es **OTROS**, si está en `dicPalabras` es **CONTENIDO**, y si no está en ninguno es **DESCONOCIDA**. Debe crear un arreglo paralelo para cada diccionario y contabilizar las apariciones de cada palabra. Adicionalmente debe contabilizar la cantidad de palabras desconocidas, otros y contenido. Finalmente, guardar en un

archivo (desconocidos.txt) las palabras desconocidas. Recuerde eliminar los signos de puntuación (:.,!).

desconocidas.txt

```
Palabra        Frecuencia
amarillos      1
fresco         1
grande         1
largo          1
llamada        1
llena          1
lleno          1
mismo          1
raro           1
tranquilo      1
```

6. Contruir el resumen general. Para ello cree una función que le permita obtener los valores a mostrar.
7. Cree el histograma de las frecuencias de las palabras de contenido del texto. Para ello primero debe ordenar los datos considerando la cantidad de apariciones de la palabra, si tienen la misma frecuencia ordenar las palabras alfabéticamente y luego escribirlas como se muestra en el reporte2.
8. Ordene por frecuencia las palabras de categorías u otros y cree el reporte tres, en el solo se consideran las categorías otros y contenido presentes en el texto.

Las búsquedas y ordenamientos deben ser funciones propias y separadas.

Reporte 1: Resumen general

```
============================================================
REPORTE 1: RESUMEN GENERAL
============================================================

Categoria       Tokens        %  Distintas
CONTENIDO          271    49.18        153
OTROS              270    49.00         52
DESCONOCIDA         10     1.81         10
```

Reporte 2: Histograma (cada # = 1 aparición)

```
lucia      | ################## (17)
lobo       | ########### (11)
perro      | ######## (8)
abuelo     | ####### (7)
bosque     | ####### (7)
pan        | ####### (7)
```

```
muchacha   | ###### (6)
camino     | #### (4)
canasto    | #### (4)
casa       | #### (4)
….
```

Reporte 3: Ranking general ✓

```
Pos   Palabra      Categoria      Frec
1     el           OTROS            50
2     y            OTROS            36
3     la           OTROS            21
4     de           OTROS            19
5     lucia        CONTENIDO        17
6     un           OTROS            16
7     en           OTROS            11
8     lobo         CONTENIDO        11
9     al           OTROS             9
10    con          OTROS             9
```

Objetivos del laboratorio del 2 de noviembre

- ordenamiento de char ** ✓
- arreglos paralelos y ordenamiento de multicriterio ✓
- uso de la librería ✓
- búsqueda binaria ✓
- inserción ordenada ✓
- lectura de archivos de texto getline ✓
- manejo de archivos
- manejo de cadenas de caracteres
- manejo de arreglos de cadenas de caracteres
- modular las funciones
- consideración de complejidad en las funciones